

URBANIS AI

Localizador Estratégico de Negócios

Relatório de Aplicação de Machine Learning

Projeto Integrador (PI) — Entrega 2

Projeto: Urbanis AI — Localizador Estratégico de Negócios

Professora Orientadora: Lucy Mari

Integrantes:

Cássio Gonçalves Gama — RA: 22023292

Luiz Eduardo Souza Rocha — RA: 24026664

Henrique Jorge Martins Figueiredo — RA: 24026809

Renan Damprelli Cardoso da Silva — RA: 24026623

Pedro Augusto da Silva Macedo — RA: 21010681

URBANIS AI | RELATÓRIO DE MACHINE LEARNING

1. Aplicação de Machine Learning

Para o projeto Urbanis, na etapa de Machine Learning (ML), foi implementado um modelo de **Aprendizado Não Supervisionado** utilizando o algoritmo **K-Means Clustering**. O objetivo é analisar a base de dados simulada de bairros em São Paulo e agrupar automaticamente os locais em "Perfis de Investimento", criando segmentações inteligentes com base na semelhança dos dados.

Lógica do Algoritmo

O algoritmo avalia cada bairro calculando a distância vetorial entre eles através de suas 4 variáveis numéricas: renda média,

criminalidade, custo de aluguel e densidade comercial. O algoritmo foi configurado com $k=3$ para formar três perfis distintos de regiões na cidade.

O trecho de código abaixo demonstra a aplicação e a padronização dos dados:

```
# Importação das bibliotecas de ML
from sklearn.cluster import KMeans
from sklearn.preprocessing import MinMaxScaler
import pandas as pd

# Carregamento da base e separação das features
df_bairros = pd.DataFrame(bairros_db)
features = df_bairros[['renda', 'criminalidade', 'aluguel', 'densidade']]

# Normalização de [0, 1] - Passo Crítico para o K-Means
scaler = MinMaxScaler()
features_normalized = scaler.fit_transform(features)
```

2. Resultados Aplicados (Entrada e Saída)

Exemplo de Entrada (Parâmetros Brutos):

- Base de dados contendo 15 bairros simulados de São Paulo.
- **Features analisadas:** Renda Média (R\$), Índice de Criminalidade (%), Aluguel (R\$/m²) e Densidade Comercial (escala 0-100). Nesta fase, não há interferência de pesos humanos.

Exemplo de Saída (Grupos Identificados pela IA):

A ferramenta formou os três clusters abaixo. O sistema Urbanis batizou essas segmentações matemáticas para criar valor comercial ao usuário final:

- **Cluster 0 (Polos Comerciais Premium):** Agrupou bairros identificados com altíssima renda e aluguéis caros. *Ex: Jardim Paulista, Itaim Bibi, Moema.*
- **Cluster 1 (Residenciais Emergentes):** Agrupou bairros com renda intermediária e índices de violência e infraestrutura variáveis. *Ex: Pinheiros, Perdizes, Vila Mariana.*
- **Cluster 2 (Áreas de Custo-Benefício):** Identificou áreas com custo de operação mais barato (aluguel menor) e densidade comercial média. *Ex: Santana, Tatuapé, Lapa.*

3. Observações Reflexivas do Grupo

A integração da ferramenta de Machine Learning permitiu transformar a plataforma Urbanis de um simples "buscador" para um ambiente de "inteligência de mercado". A seguir, as principais reflexões do grupo:

- **Descoberta de Padrões:** O algoritmo reuniu no mesmo grupo áreas geograficamente opostas (como Santana na ZN e Tatuapé na ZL), provando que a IA enxerga similaridades mercadológicas que fogem do preconceito geográfico do usuário comum.
- **Dificuldades com a Escala:** Antes de aplicarmos a normalização dos dados, o algoritmo falhou ao agrupar os bairros baseando-se quase que exclusivamente na renda. Entendemos na prática a importância do tratamento prévio dos dados no sucesso do ML.
- **Evolução do Produto:** Agora o fluxo do Urbanis está completo: o investidor primeiro visualiza os Clusters (para escolher um perfil de bairro) e depois usa a Busca Heurística (Entrega 1) apenas dentro do grupo selecionado, tornando a resposta extremamente precisa.